

Министерство образования Республики Беларусь

Учреждение образования  
БЕЛОРУССКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ  
ИНФОРМАТИКИ И РАДИОЭЛЕКТРОНИКИ

Факультет      компьютерных систем и сетей

Кафедра      Информатики

**РЕФЕРАТ**  
по учебной практике  
на тему

**МЕТОДЫ ЧАСТИЧНОГО ОБУЧЕНИЯ**

Студент (ка) гр. 556241

М.Д. Печерский

Проверила

Н.Л. Боброва

Минск 2025

## **СОДЕРЖАНИЕ**

Введение.....	3
1 Теоретические основы частичного обучения.....	5
2 Основные подходы и алгоритмы в частичном обучении.....	7
3 Применение методов частичного обучения в практических задачах .....	10
4 Преимущества, ограничения и перспективы развития.....	12
Заключение .....	15

## **ВВЕДЕНИЕ**

Современные достижения в области искусственного интеллекта и машинного обучения во многом обусловлены доступностью больших объёмов размеченных данных, которые традиционно требуются для обучения моделей в режиме с учителем. Однако на практике сбор и аннотирование данных часто сопряжены со значительными временными, финансовыми и экспертными затратами. В ряде областей — таких как медицинская диагностика, биоинформатика или анализ спутниковых снимков — получение высококачественных меток может быть принципиально затруднено из-за дефицита специалистов или этических ограничений. В этих условиях особую актуальность приобретают подходы, позволяющие эффективно обучать модели при неполной, неточной или частичной информации о целевых метках. Одним из таких направлений является частичное обучение — парадигма машинного обучения, в которой обучающая выборка содержит лишь ограниченную информацию о правильных ответах, не охватывающую все возможные классы или объекты полностью.

Интерес к методам частичного обучения в последние годы существенно возрос, что обусловлено как ростом сложности прикладных задач, так и стремлением к более рациональному использованию ресурсов в процессе разработки интеллектуальных систем. В отличие от полностью контролируемого обучения, частичное обучение допускает различные формы неполноты разметки: отсутствие меток у части объектов, наличие меток лишь для подмножества классов, неопределённость в принадлежности к конкретному классу или даже предоставление только положительных примеров без явного указания на негативные. Такая гибкость открывает возможности для построения моделей в условиях, где традиционные методы оказываются неприменимыми или неэффективными.

Целью настоящего реферата является систематизация и анализ существующих методов частичного обучения, выявление их теоретических основ, практических применений, а также обсуждение сильных и слабых сторон. В рамках работы предполагается рассмотреть ключевые алгоритмические подходы, проиллюстрировать их использование на примерах реальных задач и наметить перспективные направления дальнейших исследований. Для достижения поставленной цели были сформулированы следующие задачи: во-первых, определить понятийный аппарат и формальную постановку задачи частичного обучения; во-вторых, проанализировать основные семейства алгоритмов, применяемых в данной парадигме; в-третьих, изучить области практического

применения и оценить эффективность методов; в-четвёртых, обобщить существующие ограничения и выделить тенденции развития области.

Структура реферата отражает логику последовательного раскрытия темы: от теоретических основ к алгоритмам, от практических кейсов к критическому анализу и перспективам. Методологическую базу исследования составляют фундаментальные работы по машинному обучению, статьи ведущих конференций (NeurIPS, ICML, CVPR, ACL и др.), а также обзорные публикации, посвящённые обучению при неполной информации. Представленный материал будет полезен как исследователям, изучающим современные парадигмы машинного обучения, так и практикам, сталкивающимся с ограниченной разметкой в реальных проектах.

# 1 ТЕОРЕТИЧЕСКИЕ ОСНОВЫ ЧАСТИЧНОГО ОБУЧЕНИЯ

Частичное обучение представляет собой одну из парадигм машинного обучения, возникшую на стыке классического обучения с учителем и более гибких форм обучения при неполной информации. В отличие от традиционного подхода, при котором каждому обучающему объекту сопоставлена единственная и достоверная метка класса, в частичном обучении метка может быть задана неоднозначно — в виде множества возможных классов, среди которых лишь один является истинным. Такая постановка задачи отражает реальные условия, в которых точная разметка данных либо недоступна, либо требует непомерных усилий.

Истоки частичного обучения восходят к исследованиям в области обучения с неточной разметкой и проблемам, связанным с шумом в обучающих данных. Однако, в отличие от зашумлённой разметки, где метка ошибочна, в частичном обучении метка содержит правдивую, но неполную информацию: истинный класс обязательно присутствует среди предложенных кандидатов. Эта особенность делает задачу принципиально иной — она не столько корректирует ошибки аннотации, сколько извлекает достоверный сигнал из множества допустимых гипотез.

Формально задача частичного обучения формулируется следующим образом. Пусть задано пространство признаков  $X$  и конечное множество меток классов  $Y=\{1,2,\dots,L\}$ . Обучающая выборка состоит из пар  $(x_i, S_i)$ , где  $x_i \in X$  — вектор признаков  $i$ -го объекта, а  $S_i \subseteq Y$  — множество возможных меток, называемое частичной меткой. Предполагается, что истинная метка  $y_i$  принадлежит  $S_i$ , то есть  $y_i \in S_i$ , но неизвестно, какая именно из меток в  $S_i$  является корректной. Цель алгоритма частичного обучения — построить функцию классификации  $f:X \rightarrow Y$ , которая минимизирует ожидаемую ошибку на новых, ранее не наблюдавшихся объектах.

Такая постановка отличает частичное обучение от смежных направлений. Например, в обучении с частично наблюдаемыми метками (*semi-supervised learning*) часть объектов вообще не имеет меток, тогда как в частичном обучении метка есть у каждого объекта, но она множественная. В обучении при наличии скрытых классов (*learning with latent classes*) структура классов изначально неизвестна, тогда как в частичном обучении классы заданы явно, и неопределенность касается только принадлежности объекта к одному из них. Эти различия определяют как методологическую специфику подхода, так и круг задач, где он оказывается наиболее уместным.

Ключевым допущением, лежащим в основе большинства методов частичного обучения, является предположение о том, что частичные метки формируются по определённому вероятностному механизму. Например, часто предполагается, что для каждого объекта истинная метка включается в множество  $S_i$  с вероятностью единица, а ложные метки — с некоторой меньшей вероятностью. Это позволяет строить вероятностные модели, оценивающие правдоподобие каждой кандидатной метки и постепенно «вычищающие» ложные гипотезы в процессе обучения. Альтернативные подходы опираются на идентификацию наиболее согласованной метки на основе критериев согласованности с общей структурой данных, таких как компактность внутри классов или разделение между ними.

Таким образом, частичное обучение представляет собой самостоятельную и теоретически обоснованную парадигму, которая расширяет рамки классического машинного обучения, позволяя эффективно работать с неполной, но достоверной информацией. В следующей главе будут рассмотрены основные алгоритмические стратегии, разработанные для решения задач в рамках этой парадигмы.

## **2 ОСНОВНЫЕ ПОДХОДЫ И АЛГОРИТМЫ В ЧАСТИЧНОМ ОБУЧЕНИИ**

Развитие методов частичного обучения привело к формированию нескольких взаимодополняющих стратегий, каждая из которых основана на различных предположениях о природе неполной разметки и структуре данных. Эти подходы можно условно разделить на методы, основанные на идентификации истинных меток, методы, использующие перепараметризацию функции потерь, и методы, интегрирующие идеи самообучения и совместного обучения. Несмотря на различия в технической реализации, все они стремятся к одной цели — извлечь максимально возможную информацию из множеств частичных меток и построить модель, способную обобщать на новые данные.

Одним из самых интуитивно понятных направлений является подход, основанный на идентификации истинной метки внутри каждого множества кандидатов. Суть этого метода заключается в том, чтобы в процессе обучения оценить, какая из меток в частичной разметке наиболее вероятно соответствует истинному классу объекта. На ранних итерациях такие оценки могут быть грубыми и основываться на простых эвристиках, например, на частоте появления меток или их согласованности с соседями в признаковом пространстве. По мере уточнения модели оценки становятся всё более точными, и алгоритм постепенно сужает круг возможных меток, в конечном итоге выбирая одну — ту, которая наилучшим образом согласуется с текущей гипотезой классификатора. Такой итеративный процесс напоминает стратегию Expectation-Maximization, где на этапе ожидания уточняются вероятности меток, а на этапе максимизации обновляется модель.

Альтернативный подход заключается в модификации функции потерь, чтобы она напрямую учитывала множественный характер разметки. Вместо того чтобы требовать от модели предсказывать одну метку и штрафовать за несовпадение с единственной «правильной», функция потерь в частичном обучении может быть определена как минимум потерь по всем кандидатным меткам или как средневзвешенная сумма. Например, если для объекта задано множество  $S_i=\{2,5,7\}$ , то модель может считаться корректной, если она уверенно предсказывает хотя бы один из этих классов. Такой подход позволяет обучать модель без явного «угадывания» истинной метки, делая процесс более устойчивым к ошибкам, особенно на начальных этапах. Многие современные методы используют гибкие формы таких функций потерь, адаптируя веса

кандидатных меток в зависимости от уверенности модели или структуры выборки.

Особое место в арсенале методов частичного обучения занимают техники, заимствованные из парадигм самообучения и совместного обучения. В самообучении модель сначала обучается на объектах, для которых частичные метки содержат лишь один кандидат (то есть фактически полностью размечены), а затем применяется к объектам с более широкими множествами меток для выявления наиболее правдоподобных из них. Полученные псевдометки добавляются в обучающую выборку, и процесс повторяется. Совместное обучение предполагает наличие нескольких представлений данных — например, разных признаковых подпространств или моделей с разной архитектурой. Эти представления «сотрудничают», уточняя друг друга: если одна модель с высокой уверенностью предсказывает одну метку из множества, а другая — другую, то алгоритм может использовать согласованность или расхождение предсказаний для отбора наиболее надёжной гипотезы.

Важную роль в повышении устойчивости методов частичного обучения играют регуляризационные стратегии. Поскольку множественная разметка вносит неопределённость, модели склонны к переобучению, особенно при малом объёме данных или большом количестве классов. Для борьбы с этим применяются как классические методы регуляризации — такие как L2-штраф или дропаут, — так и специализированные техники, учитывающие структуру частичных меток. Например, можно вводить дополнительные ограничения на энтропию распределения предсказаний по кандидатным меткам, поощряя модель к более уверененным, но при этом осторожным решениям.

Наконец, в последние годы активно развиваются вероятностные и байесовские подходы, в которых каждая метка в частичном множестве рассматривается как возможное состояние скрытой переменной. С использованием методов вариационного вывода или сэмплирования можно оценить апостериорное распределение над истинными метками и интегрировать эту неопределенность непосредственно в процесс обучения. Такие методы, хотя и вычислительно затратны, демонстрируют высокую робастность и позволяют корректно оценивать доверительные интервалы предсказаний.

Таким образом, методы частичного обучения охватывают широкий спектр алгоритмических идей — от простых эвристик до сложных вероятностных моделей. Выбор конкретного подхода зависит от характера данных, структуры частичных меток и требований к интерпретируемости и вычислительной

эффективности. В следующей главе будет показано, как эти методы находят применение в реальных задачах, где полная разметка недоступна или экономически нецелесообразна.

### **3 ПРИМЕНЕНИЕ МЕТОДОВ ЧАСТИЧНОГО ОБУЧЕНИЯ В ПРАКТИЧЕСКИХ ЗАДАЧАХ**

Эффективность методов частичного обучения особенно ярко проявляется в прикладных областях, где получение точной и полной разметки данных сопряжено с серьёзными трудностями. В таких условиях частичное обучение становится не просто альтернативой, а практически необходимым инструментом, позволяющим строить рабочие модели при ограниченных ресурсах. Примеры успешного применения этих методов можно найти в медицине, компьютерном зрении, обработке естественного языка, экологии и других дисциплинах, где сложность или стоимость аннотации делают традиционное обучение с учителем нереалистичным.

В области медицинской диагностики частичное обучение находит применение при анализе клинических записей, изображений и геномных данных. Например, при классификации рентгеновских снимков или МРТ-томограмм радиолог может указать несколько возможных диагнозов, не имея достаточных оснований для однозначного заключения. Аналогично, в электронных медицинских картах часто встречаются упоминания симптомов или заболеваний без чёткой привязки к конкретному случаю — такие данные естественным образом формируют частичные метки. Модели, обученные в таком режиме, способны выявлять скрытые паттерны и поддерживать врачей в принятии решений, не требуя идеально структурированной разметки.

В компьютерном зрении частичное обучение активно используется при автоматической разметке изображений, особенно в сценариях, связанных с распознаванием объектов по описаниям. Например, при обучении на основе сопровождающих текстов к изображениям (как в датасетах из социальных сетей или новостных сайтов) часто невозможно точно определить, какой именно объект упомянут в подписи. Если подпись гласит «человек с собакой и велосипедом», но на изображении присутствуют несколько людей и транспортных средств, модель получает частичную метку, включающую все потенциально соответствующие классы. Методы частичного обучения позволяют извлекать полезную информацию даже из таких неоднозначных пар «изображение–текст», что особенно ценно для масштабного обучения без участия человека.

В обработке естественного языка подобные сценарии возникают при анализе пользовательских отзывов, новостных статей или социальных медиа. Например, при классификации тональности текста может быть известно лишь то, что отзыв содержит как положительные, так и отрицательные аспекты, но не

указано, какой из них доминирует. Или при именованной сущности в тексте система может знать, что упомянутое лицо принадлежит к одной из нескольких профессий («врач, учёный или преподаватель»), но точная роль не ясна. В таких случаях частичное обучение позволяет строить модели, устойчивые к лингвистической неопределённости и способные к дифференцированному анализу сложных текстов.

Ещё один важный класс задач — экологический и биологический мониторинг. При автоматической идентификации видов по аудио- или видеозаписям с датчиков в дикой природе эксперты часто не могут однозначно определить вид, особенно если сигнал зашумлён или виды морфологически схожи. В результате разметка может включать несколько возможных таксономических категорий. Частичное обучение позволяет использовать такие «мягкие» метки для обучения систем автоматического мониторинга биоразнообразия, что значительно расширяет масштабируемость экологических исследований.

В промышленности методы частичного обучения применяются для диагностики оборудования и предиктивного обслуживания. Датчики могут фиксировать аномалии, но точная причина сбоя неизвестна — известно лишь, что проблема связана с одной из нескольких подсистем. Частичные метки, отражающие этот спектр возможных неисправностей, позволяют обучать модели, которые со временем учатся сужать круг подозреваемых компонентов, повышая надёжность и снижая затраты на обслуживание.

Во всех этих примерах ключевым преимуществом частичного обучения является его способность максимально использовать доступную информацию, даже если она неполна. Это не только экономит ресурсы на разметку, но и делает модели более устойчивыми к реальным условиям, где идеальная информация — скорее исключение, чем правило. Более того, в некоторых случаях частичное обучение позволяет решать задачи, которые просто не поддаются постановке в рамках традиционного обучения с учителем, открывая новые горизонты для прикладного искусственного интеллекта.

## **4 ПРЕИМУЩЕСТВА, ОГРАНИЧЕНИЯ И ПЕРСПЕКТИВЫ РАЗВИТИЯ**

Методы частичного обучения предлагают значительные преимущества в условиях реального мира, где полная и достоверная разметка данных часто недоступна. Главное из них — способность эффективно использовать неполную, но честную информацию, что делает обучение более экономичным, гибким и приближённым к практическим сценариям. В отличие от методов, требующих идеальных меток, частичное обучение допускает естественную неопределённость, присущую человеческому восприятию, экспертной оценке и автоматизированным системам сбора данных. Это позволяет сократить затраты на аннотацию, ускорить разработку моделей и расширить область применимости машинного обучения на задачи, ранее считавшиеся слишком сложными или дорогими для автоматизации.

Ещё одним важным достоинством является робастность к шуму и несогласованности в разметке. Поскольку алгоритмы частичного обучения изначально рассчитаны на множественность гипотез, они менее склонны к катастрофическим ошибкам при наличии неточностей. В то время как традиционные модели могут полностью «сломаться» при одной ошибочной метке, модели частичного обучения способны абсорбировать такие неопределённости, интерпретируя их как часть нормального режима работы. Это особенно ценно в междисциплинарных приложениях, где эксперты могут расходиться во мнениях или использовать разные терминологические системы.

Однако наряду с преимуществами методы частичного обучения сталкиваются с рядом существенных ограничений. Одно из главных — зависимость качества модели от структуры и состава частичных меток. Если множества кандидатов слишком велики или содержат малоинформационные классы, процесс обучения может стать неустойчивым, а сходимость — медленной или вовсе невозможной. Особенно проблематичны случаи, когда истинный класс систематически «тонет» в большом числе ложных кандидатов, что часто происходит при автоматической генерации частичных меток без контроля со стороны эксперта.

Ещё одно ограничение — вычислительная сложность. Многие современные методы, особенно вероятностные и итеративные, требуют многократного пересчёта оценок принадлежности к классам, что увеличивает как время обучения, так и потребление памяти. Это затрудняет применение частичного обучения в задачах с очень большими объёмами данных или в условиях реального времени, где важна скорость вывода. Кроме того, отсутствие чётких

теоретических гарантий сходимости для многих эвристических подходов вызывает осторожность у исследователей, стремящихся к формальной обоснованности алгоритмов.

Также стоит отметить проблему оценки качества. В условиях частичной разметки сложно объективно измерить точность модели, поскольку истинные метки на обучающей выборке недоступны. Чаще всего приходится полагаться на косвенные метрики или использовать отдельно размеченный тестовый набор, что снижает экологическую валидность экспериментов и ограничивает возможность сравнения методов в реальных условиях.

Несмотря на эти трудности, область частичного обучения активно развивается, и в ближайшие годы можно ожидать значительного прогресса в нескольких направлениях. Во-первых, перспективным представляется интеграция с трансферным и самообучением, особенно в контексте больших предобученных моделей. Такие модели, обладающие богатыми представлениями, могут значительно улучшить качество оценки истинных меток даже при очень широких частичных множествах.

Во-вторых, растёт интерес к гибридным парадигмам, сочетающим частичное обучение с обучением с подкреплением, активным обучением или обучением с человеческой обратной связью. Например, система может сначала обучаться в режиме частичной разметки, а затем запрашивать у эксперта уточнение только в наиболее неопределённых случаях, минимизируя человеческие усилия.

В-третьих, развиваются теоретические основы частичного обучения — в частности, исследования условий, при которых возможно состоятельное восстановление истинной функции классификации, а также анализ зависимости скорости сходимости от структуры частичных меток. Такие работы приближают частичное обучение к уровню строгих математических дисциплин и открывают путь к разработке более надёжных и предсказуемых алгоритмов.

Наконец, важную роль будет играть стандартизация и создание бенчмарков. Сегодня многие исследования проводятся на синтетически сгенерированных частичных метках, что ограничивает их практическую значимость. Появление крупных реальных датасетов с естественной частичной разметкой — например, из медицинских архивов или мультиязычных корпусов — даст толчок к разработке более приближённых к практике решений.

Таким образом, несмотря на существующие вызовы, частичное обучение остаётся одной из наиболее перспективных и практически значимых парадигм современного машинного обучения. Его способность работать с реальной, «грязной» и неопределённой информацией делает его незаменимым инструментом в эпоху, когда данные легко собираются, но трудно интерпретируются.

## ЗАКЛЮЧЕНИЕ

В ходе настоящего исследования была проведена систематизация и анализ методов частичного обучения — одной из наиболее актуальных парадигм машинного обучения, ориентированной на работу с неполной, но достоверной разметкой данных. Было показано, что частичное обучение занимает промежуточное положение между традиционным обучением с учителем и более свободными формами обучения, такими как обучение без учителя или с подкреплением, и при этом обладает собственной теоретической основой и чёткой формальной постановкой задачи. В отличие от подходов, предполагающих наличие шума в метках или полное отсутствие разметки, частичное обучение исходит из предположения, что истинная метка всегда присутствует среди предложенных кандидатов, что делает его особенно подходящим для задач, где аннотация возможна лишь в виде множества гипотез.

Рассмотренные в работе алгоритмические стратегии — от методов идентификации истинных меток и модификации функций потерь до техник самообучения и вероятностного моделирования — демонстрируют богатство инструментария, доступного исследователям и практикам. Эти методы позволяют гибко адаптироваться к различным сценариям неполной информации и строить модели, устойчивые к неопределённости. Особенно важно, что частичное обучение не требует идеальных условий для сбора данных, что резко расширяет границы применимости машинного обучения в реальных областях.

Анализ практических применений подтвердил высокую востребованность данных подходов в таких сферах, как медицинская диагностика, компьютерное зрение, обработка естественного языка и экологический мониторинг. Во всех этих областях частичное обучение позволяет использовать данные, которые в противном случае пришлось бы игнорировать или дорого размечать вручную. Это делает его не просто теоретическим любопытством, а практическим решением для повышения эффективности и масштабируемости интеллектуальных систем.

Вместе с тем было выявлено, что методы частичного обучения сталкиваются с рядом существенных вызовов — от вычислительной сложности и зависимости от качества частичных меток до отсутствия универсальных теоретических гарантий и стандартных бенчмарков. Эти ограничения указывают на необходимость дальнейших исследований, направленных как на укрепление теоретической базы, так и на интеграцию с другими парадигмами машинного обучения, включая трансферное обучение, активное обучение и использование больших языковых моделей.

Таким образом, можно сделать вывод, что частичное обучение представляет собой зрелое и перспективное направление, способное эффективно решать задачи в условиях ограниченной разметки. Его развитие отвечает ключевой тенденции современного искусственного интеллекта — стремлению к более экономичным, гибким и реалистичным формам обучения. Дальнейшее совершенствование методов, расширение их теоретического обоснования и внедрение в прикладные системы будут способствовать укреплению роли частичного обучения как одного из фундаментальных инструментов машинного интеллекта будущего.